Servicios sí, topología no: qué replica un agente LLM del dataset Cloudscape y por qué el prompt engineering no cierra la brecha

Steven Martinez, Melissa Cobos

***Abstract*—Construir a mano un catálogo de arquitecturas en la nube a partir de vídeos toma meses de trabajo especializado: Cloudscape, el mayor inventario público de diseños sobre AWS, costó más de 18 persona-meses y no se actualiza desde 2023. Este artículo mide hasta qué punto un agente multimodal de dos etapas puede hacer esa tarea. Sobre 321 arquitecturas ya catalogadas, el agente reproduce el inventario de servicios con un F1 de 86,78 % y las conexiones con 59,65 %. La brecha no depende del modelo: con la misma entrada, Gemini 3.6 Flash, Gemini 3.1 Pro y Claude Opus 5.5 quedan entre 59,80 y 61,27 de F1 de conexiones. Tampoco se cierra reescribiendo las instrucciones ni leyendo mejor la pizarra: doce variantes de *prompt* no la mueven, y una persona transcribiendo el diagrama aporta 2,27 puntos. Cuando la segunda etapa recibe la referencia como entrada y se le pide conservar sus conexiones, la reproduce completa: la brecha está en lo que la pizarra no contiene, y hasta 19 de sus 43 puntos son convenciones de anotación, sobre todo el sentido de las respuestas. Al sustituir el catálogo curado a mano en un estudio publicado, su clasificación coincide en el 94,8 % de los casos, pero las cifras que dependen de flujos caen un 28 %. Procesar un vídeo cuesta unos 3 céntimos de dólar.**

PALABRAS CLAVE

Arquitecturas de software, modelos multimodales, cloud, varianza de prompts.

I. INTRODUCCIÓN

Las decisiones de diseño de los sistemas cloud que están en producción casi nunca se publican. Un lugar donde sí aparecen es la serie de vídeos *This is My Architecture* de AWS, en la que un ingeniero dibuja en una pizarra el sistema que su empresa tiene funcionando y lo explica en pocos minutos. Cloudscape convirtió 396 de esos vídeos en grafos formales y los usó para responder con datos preguntas que antes se contestaban por intuición: qué servicios se usan de verdad, con qué se conectan, cuánta variedad hay [1]. El dataset ya sirve de base a otros trabajos [2].

Construirlo costó más de 18 persona-meses de trabajo iterativo entre seis anotadores. Ese costo tiene una consecuencia concreta: el dataset se cerró en 2023 y no se ha vuelto a actualizar, aunque la serie siguió publicando vídeos. Cualquier conclusión que hoy se extraiga de él describe el estado de la práctica de hace varios años, y el trabajo derivado hereda la misma fecha de corte.

La pregunta natural es si un agente multimodal puede hacer ese trabajo. La respuesta que encontramos no es un sí ni un no: **el agente reproduce el inventario de servicios y no reproduce las conexiones entre ellos**. Reportamos las dos magnitudes por separado porque el catálogo responde dos clases de preguntas: las de inventario (qué servicios se usan y con qué frecuencia) dependen del conjunto de servicios, y las de flujo (cómo se mueven los datos, cuántos pasos tiene un proceso) dependen de las conexiones. Una cifra media escondería que las primeras ya se pueden automatizar y las segundas no.

El trabajo aporta cinco resultados:

1) **La asimetría entre servicios y conexiones**: 27 puntos de F1 sobre 321 arquitecturas, que se repiten con tres modelos de dos proveedores.
2) **Reescribir el *prompt* no cierra la brecha**: once variantes caben en 3,61 puntos, del tamaño de lo que el sistema varía por sí solo, y cinco intervenciones diseñadas a partir del análisis de error tampoco la mueven.
3) **Dónde está la brecha**: con la referencia como entrada, la segunda etapa la reproduce completa si se le pide conservar las conexiones recibidas; una lectura humana de la pizarra solo aporta 2,27 puntos. Lo que falta no está en la pizarra, y hasta 19 de los 43 puntos son convenciones de anotación.
4) **Qué le pasa a un estudio publicado** si sus datos se reemplazan por los del agente: su clasificación se mantiene en el 94,8 % de los casos y las cifras que dependen de flujos caen un 28 %.
5) **Cuánto cuesta**: unos 3 céntimos de dólar por vídeo con el modelo de producción, unos 13 dólares para todo el dataset.

Para un sistema automatizado, extraer estos grafos va más allá de reconocer logos en un fotograma. Primero, la oclusión: el presentador tapa el diagrama mientras habla y la pizarra queda despejada solo por breves instantes. Segundo, la desconexión multimodal: muchas conexiones se mencionan en voz pero nunca se dibujan, y contenedores genéricos rotulados como «AWS» esconden varios servicios nombrados en el audio. Tercero, anotar no es transcribir: el sistema no debe copiar la pizarra, sino aplicar las reglas de codificación del dataset para decidir cuándo apegarse a la línea dibujada y cuándo usar el contexto hablado.

II. METODOLOGÍA

El sistema toma la URL de un vídeo y devuelve un archivo .graphml con el esquema de Cloudscape. Descarga el vídeo con yt-dlp, transcribe el audio con Whisper sobre GPU, extrae

un fotograma cada 10 segundos, elige el mejor fotograma de pizarra y lo envía junto con la transcripción completa a un agente de dos etapas. Todo lo anterior al agente es local y no consume cuota de API.

A. Elección del fotograma

El fotograma elegido es el que reúne a la vez la mayor cantidad de servicios dibujados, la mayor cantidad de líneas entre ellos y la menor oclusión. Los servicios se detectan como regiones cuadradas de color vivo cuyo brillo contrasta con el de un marco de veinte píxeles a su alrededor; las líneas, con un detector de bordes sobre la misma zona, tapando antes los iconos y con un tope para que el ruido visual no gane; la oclusión, como la proporción de tonos de piel, que se resta y es el término con más peso. Las tres medidas se hacen sobre la franja central de la imagen, donde está la pizarra, pero el fotograma se envía completo. Se descarta el primer 20 % del vídeo y las pantallas de créditos.

B. Dos etapas

La etapa 1 tiene como objetivo producir un inventario literal de la pizarra: las entidades dibujadas y las flechas entre ellas, cada una con su etiqueta. La etapa 2 lleva ese inventario al esquema de Cloudscape: normaliza cada servicio al catálogo del dataset, fusiona los iconos repetidos de un mismo servicio cuando cumplen el mismo papel y los separa cuando hacen pasos distintos, expande los contenedores genéricos en los servicios que nombra el audio y ordena las conexiones en flujos con número de secuencia. Las dos etapas reciben, además de la imagen, la transcripción del audio, porque parte de la arquitectura solo se describe verbalmente.

Separar las etapas tiene una consecuencia que el diseño buscaba: la entrada de la etapa 2 se puede sustituir por una lectura humana de la pizarra o por la propia referencia, y eso permite medir por separado la lectura y la interpretación (Sección III-C). La salida de cada etapa se fuerza con un esquema estructurado, y las llamadas a Gemini usan temperatura 0.

a) Modelos: El sistema de producción usa `gemini-3.6-flash` en las dos etapas. Para comprobar si las conclusiones dependen del modelo repetimos parte de los experimentos con `gemini-3.1-pro-preview` y con `claude-opus-5-5`. Claude se invoca desde su cliente de línea de comandos, que no permite fijar la temperatura.

C. Conjunto de evaluación

Cloudscape tiene 396 arquitecturas. El sistema procesó 370; descartando las que los autores del dataset marcan como no utilizables y las que no tienen conexiones en la referencia quedan 321, sobre las que se reportan los resultados globales.

Los experimentos que repiten mediciones (variantes de *prompt*, oráculos y comparación de modelos) se hacen sobre un subconjunto fijo de **30 arquitecturas**, el panel. Procesarlo una vez son 30 llamadas, y el nivel gratuito de la API admitía 20 llamadas por proyecto y día: el tamaño del panel lo fija esa cuota.

D. Protocolo de evaluación

El **protocolo estricto** mide el F1 de servicios sobre el conjunto de tipos de servicio presentes, con coincidencia exacta y sin contar repeticiones, y el F1 de aristas sobre el multiconjunto de pares dirigidos (origen, destino), contando cada línea cuando hay flujos paralelos. Se mide también la exactitud de tipo: entre las conexiones correctas, qué fracción lleva el tipo de Cloudscape (`data` o `meta`).

El **protocolo permisivo** mide la calidad del grafo base, sin las convenciones de anotación. Perdona tres cosas: (i) los subtipos de actor (todo `User*` cuenta como `User`); (ii) las repeticiones de un mismo par; (iii) la dirección. Si la referencia tiene `UserConsumerWebMobile`→`CloudFront`, `Lambda`→`S3`, `S3`→`Lambda` y `ApiGateway`→`Lambda`, y el sistema pone otro subtipo de usuario, omite la respuesta de `S3` e invierte la de `ApiGateway`, el estricto da 1 de 4; la regla (i) lo lleva a 2 de 4, la (ii) reduce la referencia a 3 conexiones y la (iii) acepta la flecha invertida: 3 de 3. Los dos protocolos puntúan los mismos grafos.

La regla (iii) tiene un límite: un sistema que invirtiera todas las flechas sacaría un F1 de aristas perfecto. Por eso el permisivo se reporta como cota superior de la calidad del grafo base, junto al estricto y nunca en su lugar.

E. Piso de ruido

Un modelo de lenguaje no devuelve siempre lo mismo ante la misma entrada, ni siquiera a temperatura 0: de 170 salidas repetidas, ninguna fue idéntica carácter por carácter. Medimos esa variación con réplicas del panel sin cambiar nada. La diferencia más pequeña que el diseño distingue del ruido (MDE, con $\alpha = 0{,}05$ y potencia 0,80) es de 3,29 puntos en el F1 de aristas y de 1,76 en el de servicios. Toda comparación del panel se lee contra ese umbral.

El código, los grafos generados y los *prompts* están en https://github.com/stevenijm777/aws-architecture-extraction.

III. Resultados

A. Servicios frente a conexiones

TABLE I
DESEMPEÑO SOBRE LAS 321 ARQUITECTURAS (PROTOCOLO ESTRICTO).

	Sistema	Referencia
F1 de servicios	86,78	—
F1 de aristas	59,65	—
Brecha	**27,13**	—
Nodos por arquitectura	9,15	9,11
Aristas por arquitectura	9,04	12,42

La Tabla I contiene el resultado central: 27 puntos separan identificar los servicios de reconstruir las conexiones, y 307 de las 321 arquitecturas quedan por debajo de la diagonal (Figura 1). Los conteos muestran que el déficit no es una pérdida difusa: los nodos calzan (9,15 contra 9,11, una diferencia de $0{,}12\times$ el MDE) y las aristas quedan por debajo en 3,38 por arquitectura ($4{,}7\times$ el MDE).

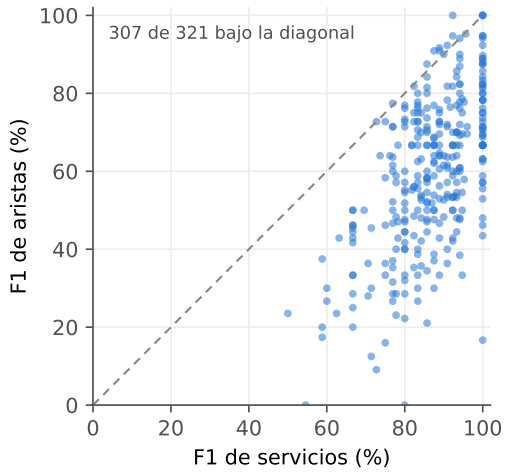


Fig. 1. F1 de servicios frente a F1 de aristas por arquitectura ($n = 321$).

La exactitud de tipo es de 61,5 %, muy por debajo de lo que daría etiquetar todo como `data`, el tipo del 81 % de las aristas de la referencia. La causa es de vocabulario: el *prompt* usa un tercer tipo, `control`, que Cloudscape no tiene, y el 30 % de las aristas generadas lo llevan.

B. *El* prompt *no cierra la brecha*

TABLE II
ONCE VARIANTES DE *prompt* DE LA ETAPA 2, PANEL DE 30.

Variante	F1 servicios	F1 aristas
V7 retorno sobre V6 (c10)	88,07	**60,10**
V6 optimizado (c8)	86,75	59,14
V6 corregido (c9) — producción	88,06	58,99
V7 flujos de retorno (c7)	86,91	58,65
V5 ruteo estricto (c8)	86,78	58,45
V8 actores y retornos	86,21	58,40
V6 corregido (c10)	88,47	58,10
V5 ruteo estricto (c7)	86,65	58,08
V6 corregido (c7)	85,92	57,52
V4 anti-alucinación (c8)	85,62	57,10
V4 *few-shot* dinámico	88,03	56,49
Rango	**2,84**	**3,61**
MDE ($n = 30$)	1,76	3,29

Entre la mejor y la peor de las once variantes de la Tabla II hay 3,61 puntos de F1 de aristas, apenas por encima de los 3,29 que el sistema se mueve solo. Comparar el extremo mejor contra el peor da 10 victorias, 7 derrotas y 13 empates ($p = 0{,}629$).

Siguiendo a Arcuri y Briand [3], reportamos el tamaño de efecto con su intervalo y no solo el valor p. Sobre las 55 comparaciones entre variantes, el $\hat{A}_{12}$ de Vargha y Delaney va de 0,452 a 0,553, y los 55 intervalos de confianza por *bootstrap* contienen el 0,5, con un ancho medio de 0,110. En la misma prueba y sobre el mismo panel, el brazo de oráculo de la Sección III-C da $\hat{A}_{12} = 0{,}861$ [0,794; 0,927]: el diseño detecta diferencias cuando las hay. Lo que sostenemos es que ninguna diferencia entre variantes es detectable, no que sean equivalentes. Ninguna comparación sobrevive tampoco a la corrección de Bonferroni o de Holm (el p mínimo es 0,0074 frente a un α corregido de 0,00091), una corrección que esos autores no recomiendan y que reportamos solo como control.

TABLE III
INTERVENCIONES DIRIGIDAS, PANEL DE 30. DIFERENCIA PAREADA CON SU LÍNEA BASE DE PRODUCCIÓN.

Intervención	Δ aristas	×MDE	signos
Evidencia visual (Hough)	−1,60	0,49	$p = 0{,}55$
V8 · actores y retornos	−0,59	0,18	$p = 0{,}61$
Auditoría de retornos	+1,20	0,36	$p = 1{,}00$
Few-shot RAG	−2,50	0,76	$p \approx 0{,}33$
V9 · conexiones autoritativas	+0,43	0,13	$p = 1{,}00$

Las cinco intervenciones de la Tabla III se diseñaron a partir de los errores más frecuentes, y ninguna alcanza el umbral. En dos de ellas se verificó que el mecanismo funcionaba: la auditoría de retornos generó propuestas válidas en el 100 % de los casos y V8 sí recuperó nodos actor. La quinta, V9, es la que corrige el experimento de oráculo (Sección III-C); en producción da +0,43 puntos y +0,03 en una segunda corrida.

C. *Dónde está la brecha*

El experimento cambia una sola cosa: de dónde sale la descripción de la pizarra que recibe la etapa 2. En **producción** la genera la etapa 1; en el **brazo A** la escribió una persona mirando solo la pizarra, sin audio y sin ver la referencia; en el **brazo B** es la referencia de Cloudscape. El *prompt*, la imagen, el audio y el evaluador no cambian.

TABLE IV
EXPERIMENTO DE ORÁCULO CON FLASH, PANEL DE 30. MEDIA DE LAS RÉPLICAS DISPONIBLES.

Entrada de la etapa 2	*Prompt*	F1 svc	F1 aristas
Etapa 1 (producción, 4 réplicas)	V6	87,10	58,13
A · transcripción humana	V6	87,82	60,40
B · *ground truth*	V6	99,57	82,17
B · *ground truth*	V9	99,72	99,54

a) Leer mejor la pizarra no ayuda.: El brazo A no se despega de producción: +2,27 puntos, 17 victorias, 7 derrotas, $p = 0{,}064$, dentro del MDE (Tabla IV). La transcripción humana, puntuada directamente contra la referencia, da 57,60 de F1 de conexiones, igual que el sistema completo: una persona sin oclusión y sin límite de tiempo también dibuja 8,63 conexiones donde la referencia tiene 12,03. Esas conexiones no están dibujadas.

b) Con la respuesta delante, el prompt *era el cuello.:* En el brazo B la etapa 2 recibe la referencia y aun así se queda en 82,17. Comparando entrada y salida arista por arista, Flash conserva los nodos (263 donde hay 262) y pierde 86 aristas: en 59 la entrada trae una conexión en los dos sentidos y la salida solo uno, y en 22 la entrada repite un mismo par y la salida lo emite una vez. El *prompt* de producción pide justificar cada arista con una flecha dibujada o una frase del audio y tratar los flujos como unidireccionales salvo evidencia

contraria; las conexiones del oráculo no traen descripción, y el modelo conserva el sentido que el audio narra y descarta el otro. La variante V9 declara autoritativas las conexiones recibidas: una arista por conexión, sin descartar sentidos ni repeticiones. Con ella Flash reproduce la referencia completa en una corrida y pierde 0,92 puntos en la segunda. Quitar solo la regla de unidireccionalidad, sin el resto de V9, no tiene efecto (81,86).

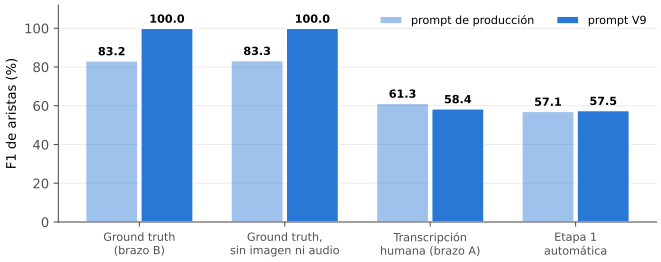


Fig. 2. F1 de aristas de Flash con el *prompt* de producción y con V9. El cambio solo altera el resultado cuando la entrada trae las conexiones.

c) Fuera del oráculo, V9 no cambia nada.: En producción da 57,55 y 57,15 frente a 57,12, y con los demás modelos queda en el mismo rango (Pro 57,52, Claude 56,18, Gemini 4 Argon 59,19); en el brazo A, 58,45 frente a 61,27 y 60,40, porque copiar la lectura humana le quita a la etapa 2 la libertad de completarla con el audio (Figura 2). La etapa 2 transporta todas las conexiones que recibe: reescribir sus instrucciones no cierra la brecha porque las conexiones que faltan no llegan en su entrada. El audio aporta, pero poco: quitárselo a la etapa 2 en el brazo A baja el F1 de aristas de 60,40 a 56,72.

d) Cuánto de la brecha es convención.: Cloudscape documenta dos reglas de anotación que la pizarra no muestra: cuando la descripción verbal no coincide con el dibujo, la referencia sigue a la verbal, y los flujos registran el grafo completo de peticiones *y respuestas* [1]. Las reglas (ii) y (iii) del protocolo permisivo perdonan justamente las repeticiones y el sentido de vuelta. En producción, el permisivo lleva el F1 de aristas de 57,12 a 76,64, y la lectura humana de 57,60 a 75,81: de los 43 puntos que separan al sistema del techo, hasta 19 son convención y unos 23 son pares de servicios que no aparecen en la pizarra. Es una cota superior, por el límite de la regla (iii).

D. ¿Depende del modelo?

TABLE V
F1 DE ARISTAS CON TRES MODELOS, PANEL DE 30. «ETAPA 1» PUNTÚA LA LECTURA DE LA PIZARRA (SOLO LA IMAGEN) CONTRA LA REFERENCIA; LAS DEMÁS COLUMNAS, LA SALIDA DE LA ETAPA 2. MEDIA DE LAS RÉPLICAS DISPONIBLES.

	Etapa 1	Brazo A	Brazo B (V6)	Brazo B (V9)
Persona	57,60	—	—	—
Gemini 3.6 Flash	53,34	60,84	82,17	99,54
Gemini 3.1 Pro	52,72	59,80	69,81	94,12
Claude Opus 5.5	52,31	60,75	82,89	97,62

Un modelo más fuerte no reduce la brecha en ninguna etapa (Tabla V). En la etapa 1, las lecturas de los tres modelos quedan entre 52,31 y 53,34 contra la referencia, y la humana las supera por entre 4,3 y 5,3 puntos. En la etapa 2, con la misma transcripción manual, Pro queda $-1{,}47$ puntos por debajo de Flash ($\text{IC}_{95\%}$ $[-5{,}63; +2{,}60]$) y Claude $-0{,}52$ ($\text{IC}_{95\%}$ $[-4{,}90; +3{,}75]$); Gemini 4 Argon, probado con la misma entrada, queda en 60,40. Lo que cambia es el conteo: Pro y Claude dibujan 11,40 y 11,20 aristas por arquitectura, cerca de las 12,03 de la referencia, frente a 9,00 de Flash; ganan recall, pierden precisión y el F1 no se mueve. El subdibujado de la Tabla I es del modelo de producción; lo que comparten los tres es no acertar cuáles conexiones faltan.

Pro muestra además el caso contrario a V9. En el brazo B con el *prompt* de producción añade 113 aristas que no están en la referencia e inventa 19 servicios, y 65 de esas aristas son las mismas que dibuja en el brazo A, donde solo tiene la lectura de la pizarra. Sin imagen ni audio sube a 87,59 y 88,75 en dos corridas: con la respuesta delante, el modelo la reescribe a partir del dibujo y la narración.

El protocolo permisivo no revela diferencias escondidas: sobre la misma entrada, los tres modelos quedan entre 93,0 y 94,0 en servicios y entre 76,6 y 79,1 en aristas (Figura 3). Con V9, las segundas corridas de los tres modelos difieren de las primeras en menos de un punto.

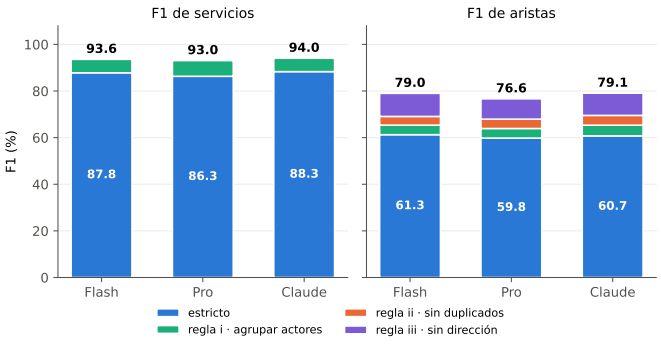


Fig. 3. Protocolo estricto y aporte de cada regla del permisivo, por modelo, con la misma transcripción manual como entrada (brazo A).

E. Costo

TABLE VI
COSTO POR VÍDEO A LAS TARIFAS PUBLICADAS EN OCTUBRE DE 2026. TOKENS MEDIOS DE LA ETAPA 2; EL COSTO SUMA LAS DOS ETAPAS CUANDO AMBAS SE MIDIERON.

Modelo	Entrada	Salida	USD/vídeo	396 vídeos
Gemini 3.6 Flash	4 802	3 845	0,033	13
Gemini 3.1 Pro	4 802	5 851	0,145	58
Claude Opus 5.5	10 371	3 875	0,139*	—
Gemini 4 Argon	5 400	2 019	0,031*	—

*Solo la etapa 2. Claude: costo equivalente de API informado por su cliente. Argon: tarifa vigente hasta noviembre de 2026.

Con el modelo de producción, procesar un vídeo cuesta unos 3 céntimos de dólar (Tabla VI) y rehacer las 396 arquitecturas, unos 13 dólares, frente a los 18 persona-meses del catálogo original. La salida incluye los tokens de razonamiento, que son el 52 % del costo de la etapa 2 con Flash y el 63 % con Pro; la etapa 1 de Pro se midió sobre 7 vídeos. La tarifa de Flash es

promocional hasta finales de 2026 y se duplica después; aun así, mantener el catálogo al día con los vídeos nuevos de la serie, unos 20 al mes en su punto más alto, cuesta menos de un dólar al mes.

F. ¿Sirven estos grafos en un estudio publicado?

Ejecutamos el código de Santillán y Abad [2], que clasifica cada arquitectura como HPC, Edge, ambas o ninguna a partir de los servicios presentes, sustituyendo su corpus anotado a mano por los grafos del sistema sobre las mismas 385 arquitecturas. Lo único que cambia es quién leyó la pizarra.

TABLE VII
CLASIFICACIÓN HPC/EDGE CON LOS GRAFOS DEL SISTEMA (385 ARQUITECTURAS).

Resultado	Valor
Coincidencia de clasificación	365/385 = 94,8 %
Top-10 preservado (HPC / Edge / None)	7 / 8 / 9

En ese clasificador basta que falte un servicio para que una arquitectura cambie de categoría, y aun así coincide en el 94,8 % de los casos. La mayoría de los desacuerdos se explica por un único nodo de actor perdido (un dispositivo, no un servicio de AWS). En la parte del estudio que depende de la topología, el conteo de *workflows*, la conclusión cualitativa de los autores se mantiene, pero las medias caen alrededor de un 28 %, porque el sistema subcuenta *workflows* igual que subdibuja aristas.

El sistema procesa además 61 arquitecturas que Cloudscape no cubre, 33 de ellas de 2024. Clasificadas con la misma regla, la proporción de arquitecturas Edge pasa de 25,5 % a 27,4 % entre las 457 resultantes. Es una actualización del catálogo, no una tendencia: los autores advierten que la variación anual de la serie puede deberse a la curaduría del canal.

IV. TRABAJO RELACIONADO

La reconstrucción de arquitecturas recupera el diseño de un sistema a partir de su código fuente [4], y las comparaciones de técnicas automáticas encuentran que incluso la mejor tiene una precisión sorprendentemente baja al recuperar la estructura [5]. Este trabajo no parte del código sino de vídeos en los que un ingeniero dibuja y explica su arquitectura. Los propios autores de Cloudscape probaron modelos generativos multimodales con ejemplos y ajuste de *prompts* para ayudar a la anotación, con baja precisión [1]; aquí medimos por separado qué parte de la tarea ya se puede automatizar y por qué la otra no.

Los modelos de lenguaje razonan peor sobre grafos a medida que estos se vuelven más complejos, y el beneficio de las técnicas de *prompting* disminuye en los problemas más difíciles [6], [7]. Esa literatura llevaría a esperar que el límite estuviera en el modelo o en la instrucción; nuestros resultados lo sitúan en la entrada. Para no confundir sensibilidad al texto con mejora real evaluamos varias instrucciones y no una sola [8], con las pruebas y tamaños de efecto que recomiendan Arcuri y Briand [3]. El experimento de oráculo sigue la idea de evaluar una etapa suponiendo perfecta la anterior, como en la evaluación de reparación automática con localización de fallos perfecta [9].

V. LIMITACIONES

Todas las cifras se comparan contra una única anotación de referencia, y casi toda la brecha corresponde a conexiones que no están en la pizarra; no sabemos qué parte de ellas es recuperable del vídeo y qué parte es criterio del anotador. Los experimentos con otros modelos se hicieron sobre el panel de 30, varias condiciones tienen una sola corrida, a Claude no se le puede fijar la temperatura y la transcripción manual la hizo una sola persona.

VI. CONCLUSIONES

Un agente multimodal de dos etapas ya reproduce el inventario de servicios de una arquitectura (86,78 de F1) y no reproduce sus conexiones (59,65). La extracción automática sirve hoy para las preguntas que dependen del conjunto de servicios, y su costo, unos 13 dólares por todo el catálogo, permite mantenerlo al día; las preguntas que dependen de flujos siguen necesitando revisión humana.

La brecha no se cierra cambiando el modelo, reescribiendo las instrucciones ni leyendo mejor la pizarra. Cuando la segunda etapa recibe las conexiones correctas las transporta todas; las que faltan no están en lo que el sistema ve, y una parte importante son convenciones de anotación, como registrar la respuesta de cada petición. Quedan dos líneas de trabajo: medir el acuerdo entre dos anotadores sobre un subconjunto del dataset, para saber cuánto del desacuerdo es error del sistema, y tratar la narración del vídeo como fuente primaria de conexiones y no como contexto de apoyo.

REFERENCES

[1] S. Satija, C. Ye, R. Kosgi, A. Jain, R. Kankaria, Y. Chen, A. C. Arpaci-Dusseau, R. H. Arpaci-Dusseau, and K. Srinivasan, "Cloudscape: A study of storage services in modern cloud architectures," in *23rd USENIX Conference on File and Storage Technologies (FAST 25)*, (Santa Clara, CA), pp. 103–121, USENIX Association, Feb. 2025.

[2] S. Santillan and C. L. Abad, "An analysis of hpc and edge architectures in the cloud," 2025.

[3] A. Arcuri and L. Briand, "A practical guide for using statistical tests to assess randomized algorithms in software engineering," in *Proceedings of the 33rd International Conference on Software Engineering*, ICSE '11, (New York, NY, USA), p. 1–10, Association for Computing Machinery, 2011.

[4] S. Ducasse and D. Pollet, "Software architecture reconstruction: A process-oriented taxonomy," *IEEE Transactions on Software Engineering*, vol. 35, no. 4, pp. 573–591, 2009.

[5] J. Garcia, I. Ivkovic, and N. Medvidovic, "A comparative analysis of software architecture recovery techniques," in *2013 28th IEEE/ACM International Conference on Automated Software Engineering (ASE)*, pp. 486–496, 2013.

[6] B. Fatemi, J. Halcrow, and B. Perozzi, "Talk like a graph: Encoding graphs for large language models," 2023.

[7] H. Wang, S. Feng, T. He, Z. Tan, X. Han, and Y. Tsvetkov, "Can language models solve graph problems in natural language?," 2024.

[8] M. Mizrahi, G. Kaplan, D. Malkin, R. Dror, D. Shahaf, and G. Stanovsky, "State of what art? a call for multi-prompt llm evaluation," 2024.

[9] K. Liu, A. Koyuncu, T. F. Bissyandé, D. Kim, J. Klein, and Y. L. Traon, "You cannot fix what you cannot find! an investigation of fault localization bias in benchmarking automated program repair systems," 2019.